

Classificação de Imagens com Redes Neurais Artificiais*

Tiago C A Amorim (RA: 100675)^a, Taylon L C Martins (RA: 177379)^b

^aDoutorando no Departamento de Engenharia de Petróleo da Faculdade de Engenharia Mecânica, UNICAMP, Campinas, SP, Brasil

^bAluno especial, UNICAMP, Campinas, SP, Brasil

Keywords: Classificação, Redes Neurais Artificiais

1. Introdução

Este relatório apresenta as principais atividades realizadas no desenvolvimento das atividades propostas na Lista 03 da disciplina IA048: Aprendizado de Máquina, primeiro semestre de 2024. O foco deste exercício é de construir e avaliar o desempenho de redes neurais artificiais, MLP (densas de uma camada) e CNN (convolucionais), na classificação de imagens de células sanguíneas periféricas.

2. Tarefa Proposta

Nesta atividade, vamos abordar o problema de reconhecimento de células sanguíneas periféricas utilizando a base de dados BloodMNIST [1, 2, 3] (<https://medmnist.com/>), a qual possui 17.092 imagens microscópicas coloridas (3 canais de cor). O mapeamento entre os identificadores das classes e os rótulos está indicado na Tabela 1.

Id	Rótulo
0	Basófilos
1	Eosinófilos
2	Eritroblastos
3	Granulócitos imaturos
4	Linfócitos
5	Monócitos
6	Neutrófilos
7	Plaquetas

Tabela 1: Correspondência entre os identificadores numéricos das classes e os tipos de células sanguíneas.

- (a) Aplique uma rede MLP com uma camada intermediária e analise (1) a acurácia e (2) a matriz de confusão para os dados de teste obtidas pela melhor versão desta rede. Descreva a metodologia e a arquitetura empregada, bem como todas as escolhas feitas.
- (b) Monte uma CNN simples contendo:

- Uma camada convolucional com função de ativação não-linear.
- Uma camada de *pooling*.
- Uma camada de saída do tipo *softmax*.

Avalie a progressão da acurácia junto aos dados de validação em função:

- Da quantidade de *kernels* utilizados na camada convolucional;
- Do tamanho do *kernel* de convolução.

- (c) Escolhendo, então, a melhor configuração para a CNN simples, refaça o treinamento do modelo e apresente:

- A matriz de confusão para os dados de teste;
- A acurácia global;
- Cinco padrões de teste que foram classificados incorretamente, indicando a classe esperada e as probabilidades estimadas pela rede.

Discuta os resultados obtidos.

- (d) Explore, agora, uma CNN um pouco mais profunda. Descreva a arquitetura utilizada e apresente os mesmos resultados solicitados no item (c) para o conjunto de teste. Por fim, faça uma breve comparação entre os modelos estudados neste exercício.

3. Aplicação

Toda a avaliação foi feita em um único *notebook* Jupyter, em Python. Foi feito o uso da biblioteca *TensorFlow* [4] para fazer as diferentes manipulações nos dados. O código pode ser encontrado em https://github.com/TiagoCAAmorim/machine_learning.

*Relatório número 03 como parte dos requisitos da disciplina IA048: Aprendizado de Máquina.

Método	AUC ¹	Acurácia
ResNet-18 (28)	0.998	0.958
ResNet-18 (224)	0.998	0.963
ResNet-50 (28)	0.997	0.956
ResNet-50 (224)	0.997	0.950
auto-sklearn	0.984	0.878
AutoKeras	0.998	0.961
Google AutoML Vision	0.998	0.966

Tabela 2: Resultados reportados na publicação original [2].

3.1. Rede MLP

3.2. Rede Convolutacional Simples

3.3. Rede Convolutacional Profunda

4. Análise dos Resultados

5. Conclusão

Referências

- [1] J. Yang, R. Shi, B. Ni, Medmnist classification decathlon: A lightweight automl benchmark for medical image analysis, in: IEEE 18th International Symposium on Biomedical Imaging (ISBI), 2021, pp. 191–195.
- [2] J. Yang, R. Shi, D. Wei, Z. Liu, L. Zhao, B. Ke, H. Pfister, B. Ni, Medmnist v2-a large-scale lightweight benchmark for 2d and 3d biomedical image classification, Scientific Data 10 (1) (2023) 41.
- [3] A. Acevedo, A. Merino González, E. S. Alférez Baquero, Á. Molina Borrás, L. Boldú Nebot, J. Rodellar Benedé, A dataset of microscopic peripheral blood cell images for development of automatic recognition systems, Data in brief 30 (article 105474) (2020).
- [4] M. Abadi, A. Agarwal, P. Barham, E. Brevdo, Z. Chen, C. Citro, G. S. Corrado, A. Davis, J. Dean, M. Devin, S. Ghemawat, I. Goodfellow, A. Harp, G. Irving, M. Isard, Y. Jia, R. Jozefowicz, L. Kaiser, M. Kudlur, J. Levenberg, D. Mané, R. Monga, S. Moore, D. Murray, C. Olah, M. Schuster, J. Shlens, B. Steiner, I. Sutskever, K. Talwar, P. Tucker, V. Vanhoucke, V. Vasudevan, F. Viégas, O. Vinyals, P. Warden, M. Wattenberg, M. Wicke, Y. Yu, X. Zheng, TensorFlow: Large-scale machine learning on heterogeneous systems, software available from tensorflow.org (2015).
URL <https://www.tensorflow.org/>

¹AUC = *Area Under Curve*. É a área sob a curva da Taxa de Verdadeiros Positivos (*Recall*) em função da Taxa de Falsos Positivos (*1-Especificidade*).