

Modelos de Fluxo Substitutos com Redes Convolucionais Recorrentes*

Tiago Corrêa de Araújo de Amorim (RA: 100675) t100675@dac.unicamp.br^a,
Taylon Luan Congio Martins (RA: 177379) t177379@m.unicamp.br^b

^aDoutorando no Departamento de Engenharia de Petróleo da Faculdade de Engenharia Mecânica, UNICAMP, Campinas, SP, Brasil

^bAluno especial, UNICAMP, Campinas, SP, Brasil

Keywords: Fluxo em Meio Poroso, Redes Neurais Recorrentes, Rede Neurais Convolucionais

1. Introdução

Na indústria do petróleo é comum o uso de simuladores de fluxo tridimensionais para realizar a previsão de produção de acumulações de hidrocarbonetos [1, 2]. Estas simulações são empregadas em diferentes análises, desde a avaliação de valor para aquisição de blocos exploratórios, passando pelo planejamento de novos campos e, entre outros, a otimização de operações ao longo da exploração.

O nível de sofisticação das formulações empregadas e o tamanho dos modelos de fluxo dependem das características dos fluidos originais, técnicas utilizadas na extração de hidrocarbonetos, o tamanho e a heterogeneidade da acumulação. Mesmo fazendo uso de recursos de HPC, as simulações de fluxo de campos gigantes podem tomar dias para serem concluídas [3].

Diferentes proposta já foram feitas para tentar substituir parte da simulação de fluxo utilizando técnicas *tradicionais* [4] ou baseadas em inteligência artificial [5]. Entre as diferentes propostas feitas com o uso de redes neurais é mais comum o foco em realizar novas previsões a partir de séries temporais [6, 7, 8] ou de modelos de fluxo completos [9].

Uma proposta de arquitetura para aproximar física complexa foca no uso de redes em grafo para simular um passo de tempo [10]. Nesta rede o objetivo é que se aprenda a resolver o comportamento de um célula (ou partícula), dada a influência das células vizinhas, em um único passo de tempo. A proposta deste projeto é de aplicar algumas das ideias apresentadas no problema de fluxo em meio poroso.

2. Proposta

A técnica mais utilizada na simulação de fluxo em meios porosos é a de diferenças finitas [11, 12], que é aplicada em uma malha *aproximadamente* regular. O foco deste projeto será limitado a malhas regulares, i.e., para modelos bidimensionais os vizinhos da célula (i, j) são sempre $(i - 1, j)$, $(i + 1, j)$, $(i, j - 1)$ e $(i, j + 1)$ ¹. Desta forma não

é necessário o uso de redes em grafo. Cada célula pode ser entendida como o pixel de uma imagem, e cada propriedade como um canal desta imagem. Camadas convolucionais serão suficientes para buscar representar a influência das células vizinhas.

Como este problema apresenta simetria entre a célula e suas vizinhas, será testado o uso de camadas convolucionais com filtros (*kernels*) com pesos simétricos.

A arquitetura da rede deve seguir de forma geral a proposta apresentada em [10]:

1. **Encoder:** Transforma o estado das células para o espaço latente (filtros 1×1).
2. **Processamento:** Computa as interações de cada célula com os seus vizinhos. O processamento é feito em n recorrências (filtros 3×3 *simétricos*).
3. **Decoder:** Retorna o estado das células para o espaço regular (filtros 1×1).

O treinamento será feito com resultados de simulações de um passo de tempo. Para tal serão gerados resultados intermediários de diferentes simulações, com um dia de diferença entre os resultados.

Como a proposta inclui a construção de camadas convolucionais com características peculiares, está planejado o uso do pacote Pytorch [13]. A base de dados será construída com as saídas de simulações de fluxo baseadas no modelo Unisim IV [14]. Uma primeira avaliação será feita com modelos bidimensionais. A depender dos resultados o estudo poderá ser estendido para modelos tridimensionais.

O que se espera é construir uma rede que aprenda a gerar o estado futuro de uma célula em função do seu estado atual, dos controles de poços e da influência das células vizinhas. Desta forma esta rede pode ser utilizada de modo recursivo para gerar previsões de produção para diferentes valores das propriedades das células e dos mecanismos de controle de poço.

Referências

- [1] A. J. Rosa, R. de Souza Carvalho, J. A. D. Xavier, Engenharia de reservatórios de petróleo, Interciência, 2006.
- [2] L. P. Dake, Fundamentals of reservoir engineering, Elsevier, 1983.

*Proposta de projeto como parte dos requisitos da disciplina IA048: Aprendizado de Máquina.

¹No caso tridimensional são 6 vizinhos.

- [3] Application of High Performance Computing in Modeling Giant Fields of Saudi Arabia, Vol. All Days of SPE Kingdom of Saudi Arabia Annual Technical Symposium and Exhibition. [arXiv: https://onepetro.org/SPESATS/proceedings-pdf/11SATS/All-11SATS/SPE-149132-MS/1708897/spe-149132-ms.pdf](https://onepetro.org/SPESATS/proceedings-pdf/11SATS/All-11SATS/SPE-149132-MS/1708897/spe-149132-ms.pdf), doi:10.2118/149132-MS.
URL <https://doi.org/10.2118/149132-MS>
- [4] T. Amorim, D. J. Schiozer, Risk analysis speed-up with surrogate models, in: SPE Latin America and Caribbean Petroleum Engineering Conference, SPE, 2012, pp. SPE-153477.
- [5] T. Ertekin, Q. Sun, Artificial intelligence applications in reservoir engineering: a status check, *energies* 12 (15) (2019) 2897.
- [6] R. de Oliveira Werneck, R. Prates, R. Moura, M. M. Goncalves, M. Castro, A. Soriano-Vargas, P. R. M. Junior, M. M. Hossain, M. F. Zampieri, A. Ferreira, et al., Data-driven deep-learning forecasting for oil production and pressure, *Journal of Petroleum Science and Engineering* 210 (2022) 109937.
- [7] A. Davtyan, A. Rodin, I. Muchnik, A. Romashkin, Oil production forecast models based on sliding window regression, *Journal of Petroleum Science and Engineering* 195 (2020) 107916.
- [8] Y. D. Kim, L. J. Durlofsky, A recurrent neural network-based proxy model for well-control optimization with nonlinear output constraints, *SPE Journal* 26 (04) (2021) 1837–1857.
- [9] G. Cirac, J. Farfan, G. D. Avansi, D. J. Schiozer, A. Rocha, Deep hierarchical distillation proxy-oil modeling for heterogeneous carbonate reservoirs, *Engineering Applications of Artificial Intelligence* 126 (2023) 107076.
- [10] A. Sanchez-Gonzalez, J. Godwin, T. Pfaff, R. Ying, J. Leskovec, P. Battaglia, Learning to simulate complex physics with graph networks, in: International conference on machine learning, PMLR, 2020, pp. 8459–8468.
- [11] C. M. G. L. (CMG), *Cmg imex user’s manual*, CMG Calgary, Canada, 2022.
- [12] E. U. M. SCHLUMBERGER, Technical description, Schlumberger Ltd (2009) 519–538.
- [13] A. Paszke, S. Gross, F. Massa, A. Lerer, J. Bradbury, G. Chanan, T. Killeen, Z. Lin, N. Gimelshein, L. Antiga, et al., Pytorch: An imperative style, high-performance deep learning library, *Advances in neural information processing systems* 32 (2019).
- [14] V. Botechia, M. Correia, V. Rios, A. Davolio, S. Santos, J. Hohendorff Filho, D. Schiozer, Unisim-iv: Benchmark proposal for light oil carbonate reservoir with high co2 content, *Brazilian Journal of petroleum and Gas* 16 (4) (2023).