

# Resolução de Sistema de Equações Lineares de Matrizes Pentadiagonais com Redes Neurais Convolucionais\*

Tiago C A Amorim (RA: 100675)<sup>a</sup>, Taylon L C Martins (RA: 177379)<sup>b</sup>

<sup>a</sup>Doutorando no Departamento de Engenharia de Petróleo da Faculdade de Engenharia Mecânica, UNICAMP, Campinas, SP, Brasil

<sup>b</sup>Aluno especial, UNICAMP, Campinas, SP, Brasil

**Keywords:** Rede Neurais Convolucionais, Sistemas de Equações Lineares

## 1. Introdução

## 2. Motivação

O método das diferenças finitas é utilizado para resolver diferentes problemas físicos que podem ser descritos como equações diferenciais. O método se baseia na aproximação das derivadas por diferenças finitas (Exemplos nas equações 2.1). O domínio espaço-temporal é discretizado e a solução das equações diferenciais é aproximada nos nós desta malha [1]. O problema então é transformado em uma série de equações não-lineares, que usualmente são resolvidas por métodos numéricos, como o método de Newton-Raphson [2].

$$\frac{\partial u(x)}{\partial x} \approx \frac{u(x+h) - u(x-h)}{2h} \quad (2.1a)$$

$$\frac{\partial^2 u(x)}{\partial x^2} \approx \frac{u(x+h) - 2u(x) + u(x-h)}{h^2} \quad (2.1b)$$

É usual utilizar aproximações de derivada que utilizam os valores da função do nó e seus vizinhos diretos. Em problemas bidimensionais com malhas regulares (Figura 1) esta escolha leva a sistemas de equações com matrizes pentadiagonais (2.2). Cada equação não-linear tem termos associados a um dos nós  $(i,j)$  e seus quatro vizinhos:  $(i-1,j)$ ,  $(i+1,j)$ ,  $(i,j-1)$  e  $(i,j+1)$ . A resolução numérica deste sistema de equações não-lineares usualmente está associada a métodos iterativos, em que novas equações lineares são resolvidas. Desta forma, a resolução do problema original está associada à solução de um significativo número de sistemas de equações lineares com matriz pentadiagonal.

A proposta deste trabalho é avaliar a possibilidade de utilizar uma rede convolucional para resolver este tipo de sistema de equações lineares.

Figura 1: Esquemático de uma malha regular, com destaque para a célula  $(i,j)$  e seus vizinhos.

		$(i,j-1)$	
$(i-1,j)$	<b><math>(i,j)</math></b>	$(i+1,j)$	
	$(i,j+1)$		

## 3. Trabalhos Correlatos

Não foram encontrados muitos trabalhos com foco na resolução de sistemas de equações lineares com redes neurais. Duas formas distintas de resolução do problema foram propostas. A primeira vertente é resolver o sistema de equações lineares junto com o treinamento da rede ([3]). Uma aplicação interessante desta proposta é o de resolver sistema de grande dimensão, que possivelmente não cabem na memória disponível, e usar a rede para aprender um mapeamento que aproxima a resposta ([4]).

Uma segunda vertente é a de treinar uma rede neural com base em vários exemplos de sistemas de equações a resolver. A rede treinada é utilizada para resolver novos sistemas de equações. Uma proposta focou na solução de sistemas tridiagonais ([5]), utilizando uma série de camadas densas seguidas por conexões residuais. Um outro trabalho ([6]) foca na solução de problemas físicos associados a equações diferenciais. Este trabalho tenta primeiro encontrar uma representação densa dos dados de entrada por meio de uma rede *autoencoder*. Posteriormente a representação densa de cada amostra passa por uma outra rede neural que busca resolver o problema.

A proposta estudada neste projeto segue a segunda vertente. É feita a opção de utilizar camadas convolucionais para que a arquitetura da rede seja agnóstica à discretização do problema (tamanho da malha).

\*Projeto final como parte dos requisitos da disciplina IA048: Aprendizado de Máquina.

$$\begin{bmatrix}
a_{0,1} & a_{1,1} & 0 & \dots & 0 & a_{m,1} & 0 & \dots & 0 \\
a_{-1,2} & a_{0,2} & a_{1,2} & 0 & \dots & 0 & a_{m,2} & 0 & \dots & 0 \\
0 & a_{-1,3} & a_{0,3} & a_{1,3} & 0 & \dots & 0 & a_{m,3} & \dots & 0 \\
\vdots & & \ddots & \ddots & \ddots & & & & \ddots & \vdots \\
0 & \dots & 0 & a_{-m,n-2} & 0 & \dots & a_{-1,n-2} & a_{0,n-2} & a_{1,n-2} & 0 \\
0 & \dots & & 0 & a_{-m,n-1} & 0 & \dots & a_{-1,n-1} & a_{0,n-1} & a_{1,n-1} \\
0 & \dots & & & 0 & a_{-m,n} & 0 & \dots & a_{-1,n} & a_{0,n}
\end{bmatrix}
\begin{bmatrix}
x_1 \\
x_2 \\
x_3 \\
\vdots \\
x_{n-2} \\
x_{n-1} \\
x_n
\end{bmatrix}
=
\begin{bmatrix}
b_1 \\
b_2 \\
b_3 \\
\vdots \\
b_{n-2} \\
b_{n-1} \\
b_n
\end{bmatrix} \quad (2.2)$$

#### 4. Codificação do Sistema Linear

#### 5. Arquitetura da Rede Convolutacional

#### 6. Resultados

##### 6.1. Rede Convolutacional Simples

#### 7. Conclusão

#### Referências

- [1] D. Causon, C. Mingham, Introductory finite difference methods for PDEs, Bookboon, 2010.
- [2] R. L. Burden, J. D. Faires, A. M. Burden, Análise numérica, Cengage Learning, 2016.
- [3] A. Cichocki, R. Unbehauen, Neural networks for solving systems of linear equations and related problems, IEEE Transactions on Circuits and Systems I: Fundamental Theory and Applications 39 (2) (1992) 124–138.
- [4] Y. Gu, M. K. Ng, Deep neural networks for solving large linear systems arising from high-dimensional problems, SIAM Journal on Scientific Computing 45 (5) (2023) A2356–A2381.
- [5] Z. Jiang, J. Jiang, Q. Yao, G. Yang, A neural network-based pde solving algorithm with high precision, Scientific Reports 13 (1) (2023) 4479.
- [6] K. Kontolati, S. Goswami, G. Em Karniadakis, M. D. Shields, Learning nonlinear operators in latent spaces for real-time predictions of complex dynamics in physical systems, Nature Communications 15 (1) (2024) 5101.